Lista 1

Eksploracja danych

Justyna Dudek, album 287291 i Aleksandra Tylman, album 287294

2026-04-01

Spis treści

1 Etap 1 - Przygotowanie danych. Podstawowe informacje o danych 1
1.1 Wczytanie danych 1
1.2 Podstawowe informacje o danych 2

2 Etap 2 - Analiza opisowa - wskaźniki sumaryczne i wykresy 4
2.1 Zmienne ilościowe 4
2.2 Zmienne jakościowe 9

3 Etap 3 - Analiza opisowa z podziałem na grupy 13
3.1 Analiza zmiennych ilościowych z podziałem na lojalnych i odchodzących klientów 13
3.2 Analiza zmiennych jakościowych z podziałem na lojalnych i odchodzących klientów 20

4 Etap 4 - Podsumowanie i wnioski z przeprowadzonej analizy 23
4.1 Podsumowanie 23

1 Etap 1 - Przygotowanie danych. Podstawowe informacje o danych

1.1 Wczytanie danych

Wykorzystamy dane "WA_Fn-UseC_-Telco-Customer-Churn.csv" zawierające informacje o klientach pewnej sieci telefonii komórkowej.

Pierwszym krokiem będzie sprawdzenie podstawowych informacji na temat rozpoznania typów danych.

```r
str(dane_pierwotne)
```

```
## 'data.frame':    7043 obs. of  21 variables:
```

```
##  $ customerID      : Factor w/ 7043 levels "0002-ORFBO","0003-MKNFE",..: 5376 3963 25
##  $ gender          : Factor w/ 2 levels "Female","Male": 1 2 2 2 1 1 2 1 1 2 ...
##  $ SeniorCitizen   : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Partner         : Factor w/ 2 levels "No","Yes": 2 1 1 1 1 1 1 1 2 1 ...
##  $ Dependents      : Factor w/ 2 levels "No","Yes": 1 1 1 1 1 1 2 1 1 2 ...
##  $ tenure          : int  1 34 2 45 2 8 22 10 28 62 ...
##  $ PhoneService    : Factor w/ 2 levels "No","Yes": 1 2 2 1 2 2 2 1 2 2 ...
##  $ MultipleLines   : Factor w/ 3 levels "No","No phone service",..: 2 1 1 2 1 3 3 2 3
##  $ InternetService : Factor w/ 3 levels "DSL","Fiber optic",..: 1 1 1 1 2 2 2 1 2 1 .
##  $ OnlineSecurity  : Factor w/ 3 levels "No","No internet service",..: 1 3 3 3 1 1 1
##  $ OnlineBackup    : Factor w/ 3 levels "No","No internet service",..: 3 1 3 1 1 1 3
##  $ DeviceProtection: Factor w/ 3 levels "No","No internet service",..: 1 3 1 3 1 3 1
##  $ TechSupport     : Factor w/ 3 levels "No","No internet service",..: 1 1 1 3 1 1 1
##  $ StreamingTV     : Factor w/ 3 levels "No","No internet service",..: 1 1 1 1 1 3 3
##  $ StreamingMovies : Factor w/ 3 levels "No","No internet service",..: 1 1 1 1 1 3 1
##  $ Contract        : Factor w/ 3 levels "Month-to-month",..: 1 2 1 2 1 1 1 1 1 2 ...
##  $ PaperlessBilling: Factor w/ 2 levels "No","Yes": 2 1 2 1 2 2 2 1 2 1 ...
##  $ PaymentMethod   : Factor w/ 4 levels "Bank transfer (automatic)",..: 3 4 4 1 3 3 2
##  $ MonthlyCharges  : num  29.9 57 53.9 42.3 70.7 ...
##  $ TotalCharges    : num  29.9 1889.5 108.2 1840.8 151.7 ...
##  $ Churn           : Factor w/ 2 levels "No","Yes": 1 1 2 1 2 2 1 1 2 1 ...
```

Ponieważ nie zgadzają się zmienne *customerID* oraz *SeniorCitizen*, przekonwertujemy je na odpowiedni typ.

```
dane_pierwotne$SeniorCitizen<-as.factor(dane_pierwotne$SeniorCitizen)
levels(dane_pierwotne$SeniorCitizen)<-c("No","Yes")
dane_pierwotne$customerID<-as.character(dane_pierwotne$customerID)
```

Po dokonanej zmianie dane są zakodowane poprawnie.

1.2 Podstawowe informacje o danych

Rozmiar danych to 7043 na 21. Oznacza to, że analizowane dane to zbiór informacji składający się z 7043 obserwacji (klientów) i 21 cech.

Zbiór danych posiada informacje na temat cech ilościowych i jakościowych:

- nazwy cech ilościowych;

```
## [1] "tenure"         "MonthlyCharges" "TotalCharges"
```

- nazwy cech jakościowych.

```
##  [1] "gender"           "SeniorCitizen"    "Partner"          "Dependents"
##  [5] "PhoneService"     "MultipleLines"    "InternetService"  "OnlineSecurity"
##  [9] "OnlineBackup"     "DeviceProtection" "TechSupport"      "StreamingTV"
## [13] "StreamingMovies"  "Contract"         "PaperlessBilling" "PaymentMethod"
```

```
## [17] "Churn"
```

W danych występuje cecha, która pełni rolę identyfikatorów klientów. Jest to *customerID*. Należy usunąć ją przed dalszą analizą.

Po dokonanej zmianie wszystkie występujące cechy są przydatne w analizie.

W danych występują dane brakujące. Najpierw sprawdzamy ile jest danych brakujących, następnie w której kolumnie się znajdują, a potem wyświetlamy w jaki sposób prezentujemy dane brakujące (w kodzie wyświetlamy zmienne *gender*, *SeniorCirizen*, *Partner*, *MonthlyCharges*, *TotalCharges* i *Churn*).

```
## [1] 11
```

```
##           gender    SeniorCitizen          Partner       Dependents
##                0                0                0                0
##           tenure     PhoneService    MultipleLines  InternetService
##                0                0                0                0
##   OnlineSecurity     OnlineBackup DeviceProtection      TechSupport
##                0                0                0                0
##      StreamingTV  StreamingMovies         Contract PaperlessBilling
##                0                0                0                0
##    PaymentMethod   MonthlyCharges     TotalCharges            Churn
##                0                0               11                0
```

```
##      gender SeniorCitizen Partner MonthlyCharges TotalCharges Churn
## 489  Female            No     Yes          52.55           NA    No
## 754    Male            No      No          20.25           NA    No
## 937  Female            No     Yes          80.85           NA    No
## 1083   Male            No     Yes          25.75           NA    No
## 1341 Female            No     Yes          56.05           NA    No
## 3332   Male            No     Yes          19.85           NA    No
## 3827   Male            No     Yes          25.35           NA    No
## 4381 Female            No     Yes          20.00           NA    No
## 5219   Male            No     Yes          19.70           NA    No
## 6671 Female            No     Yes          73.35           NA    No
## 6755   Male            No      No          61.90           NA    No
```

Dane brakujące są kodowane jako NA.

W analizowanym zbiorze znajdują się również dane posiadające wartości oznaczające brak usług, tj. "No phone service","No internet signal". Są one powiązane z cechami *PhoneService* i *InternetService*. Mogą być one traktowane jako nietypowy sposób kodowania danych brakujących. Przykład jak wyglądają te nietypowe dane (*gender*, *SeniorCirizen*, *Partner*, *MultipleLines*, *TotalCharges* i *Churn*).

```r
head(dane_pierwotne[dane_pierwotne$MultipleLines=="No phone service",c(1,2,3,7,19,20)])
```

```
##    gender SeniorCitizen Partner    MultipleLines TotalCharges Churn
```

```
## 1  Female            No     Yes No phone service        29.85    No
## 4    Male            No      No No phone service      1840.75    No
## 8  Female            No      No No phone service       301.90    No
## 21   Male           Yes      No No phone service        39.65   Yes
## 28   Male            No     Yes No phone service        30.20   Yes
## 63   Male            No     Yes No phone service      2962.00    No
```

Dla ułatwienia dalszej analizy zamienimy wartości "No phone service" i "No internet signal" na dane brakujące.

```
dane_pierwotne<-dane_pierwotne %>% mutate(across(c(OnlineSecurity,OnlineBackup,DevicePr
dane<-dane_pierwotne%>%mutate(across(c(MultipleLines),na_if,"No phone service"))
```

2 Etap 2 - Analiza opisowa - wskaźniki sumaryczne i wykresy

2.1 Zmienne ilościowe

2.1.1 Wyznaczenie podstawowych wskaźników sumarycznych.

zmienna	minimum	mediana	srednia	maximum	dominanta	średnia ucinana
tenure	0.00	29.00	32.37	72.00	1.00	31.43
MonthlyCharges	18.25	70.35	64.76	118.75	20.05	64.97
TotalCharges	18.80	1397.47	2283.30	8684.80	20.20	1970.14

Tabela 1: Miary położenia dla wszystkich klientów

zmienna	wariancja	odchylenie standradowe	rozstep proby	rozstep miedzy-kwartylowy
tenure	603.17	24.56	72.00	46.00
MonthlyCharges	905.41	30.09	100.50	54.35
TotalCharges	5138252.41	2266.77	8666.00	3393.29

Tabela 2: Miary rozproszenia dla wszystkich klientów

Tabela 1 przedstawia miary położenia, tzn. minimum, medianę, średnią, maksimum, dominantę i średnią ucinaną poszczególnych zmiennych ilościowych, natomiast tabela 2 ukazuje ich miary rozproszenia, tj. wariancję, odchylenie standardowe, rozstęp próby i rozstęp międzykwartylowy. Z zestawienia wynika, że zakres liczby miesięcy przez którą klient pozostawał z firmą (zmiennej tenure) to od 0 do 72 miesięcy. Zakres opłaty naliczanej na konto klienta co miesięc (zmiennej MonthlyCharges) to od 18.25 do 118.75, natomiast zakres łącznej opłaty zapłaconej przez klienta ogółem (zmiennej TotalCharges) to od 18.8 do 8684.8

2.1.2 Wykresy rozkładów

Tak prezentują się rozkłady poszczególnych zmiennych ilościowych.

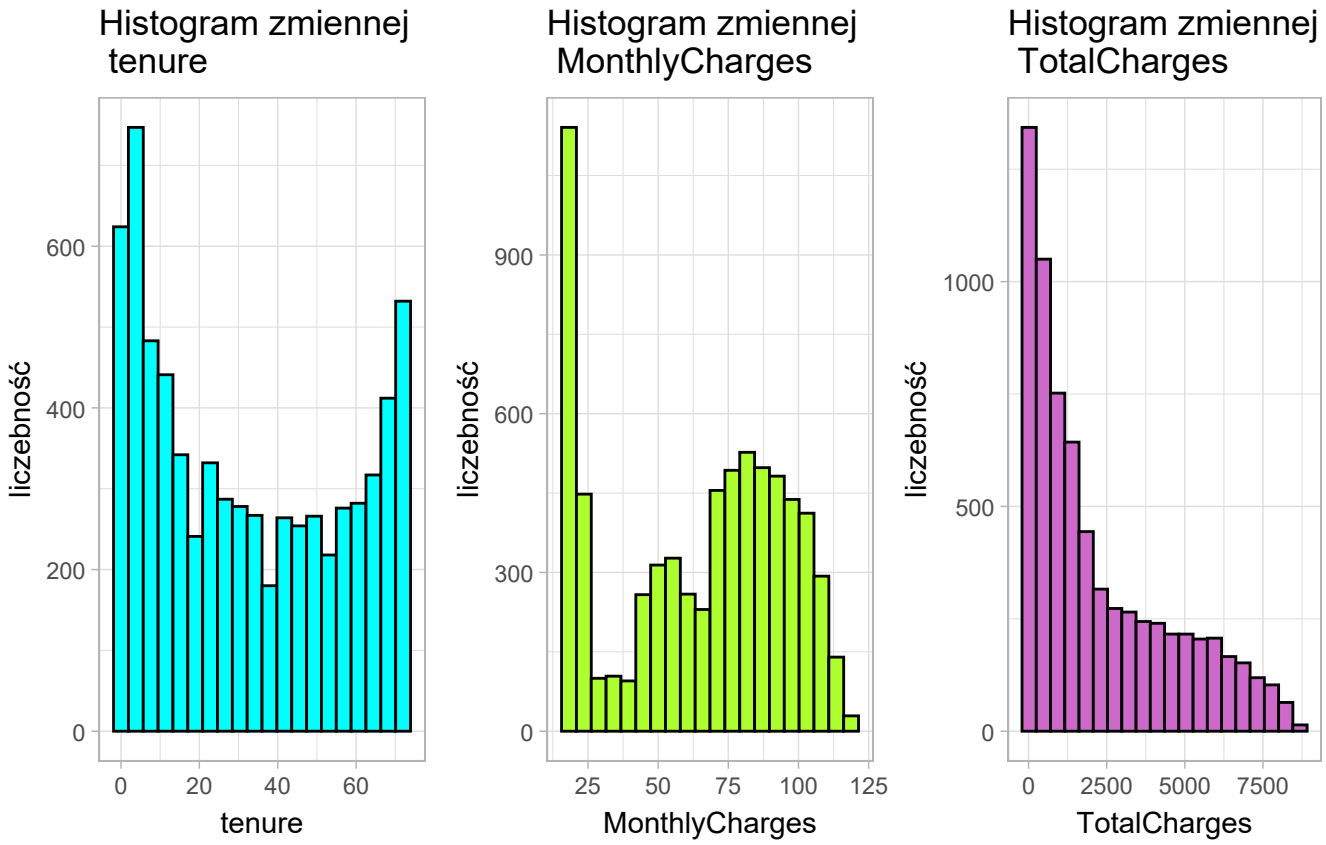

Rysunek 1: Histogramy dla zmiennych ilościowych

Z zestawienia histogramów (Rysunek 1) wynikają następujące obserwacje i wnioski:

- Zmienna tenure jest dwu-modalna, prawosstronnie skośna ze skośnością 0.24, czyli ma asymetryczny ogon z prawej strony;
- Zmienna MonthlyCharges jest dwu-modalna ze skośnością -0.22;
- Zmienna TotalCharges ma rozkład prawostronnie skośny ze skośnością 0.96, czyli ma asymetryczny ogon z prawej strony.

Wynika z tego, że analizowane zmienne ilościowe mają różne rozkłady i nie wszystkie są symetryczne.

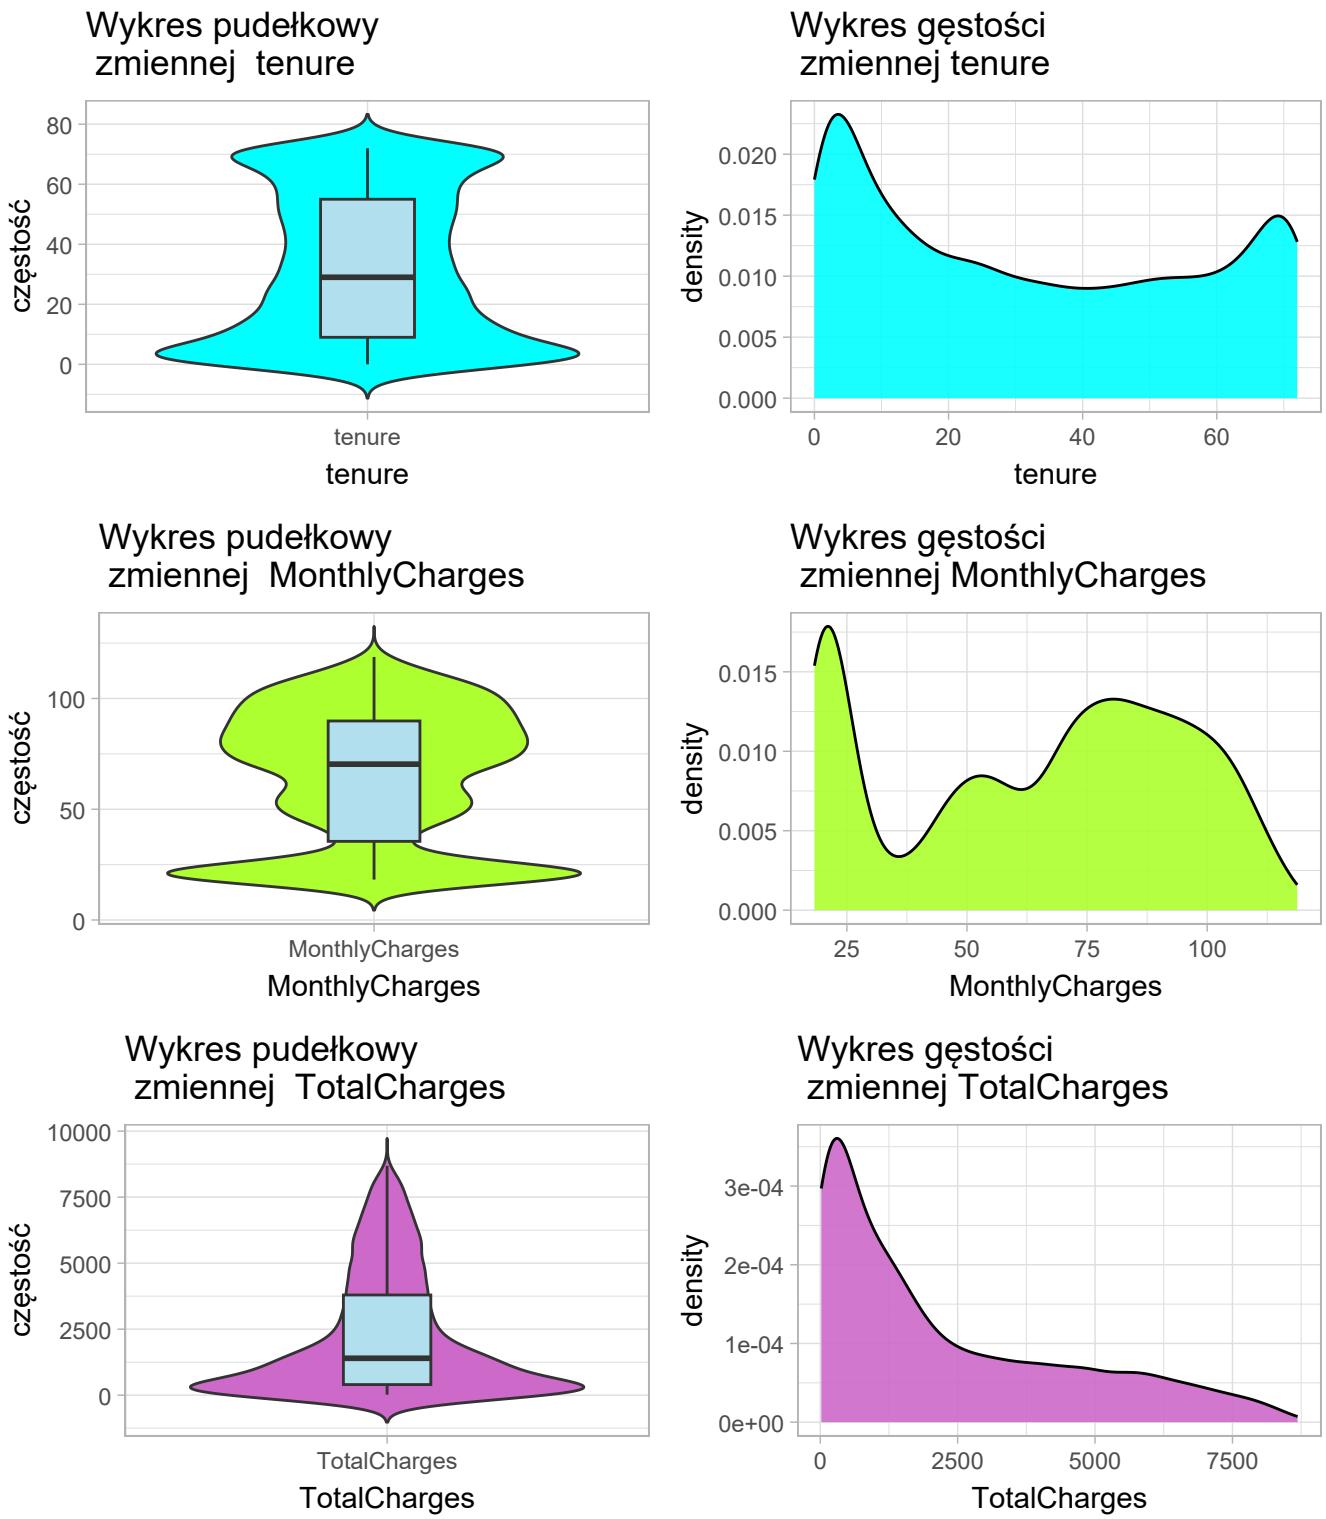

Rysunek 2: Wykresy pudełkowe,skrzypcowe i gętości dla zmiennych ilościowych

Rysunek (2) prezentuje, że największą zmiennością charakteryzuje się kwota opłaty płaconej przez klienta co miesiąc (zmienna MonthlyCharges).

2.1.3 Wykresy rozrzutów par zmiennych ciągłych

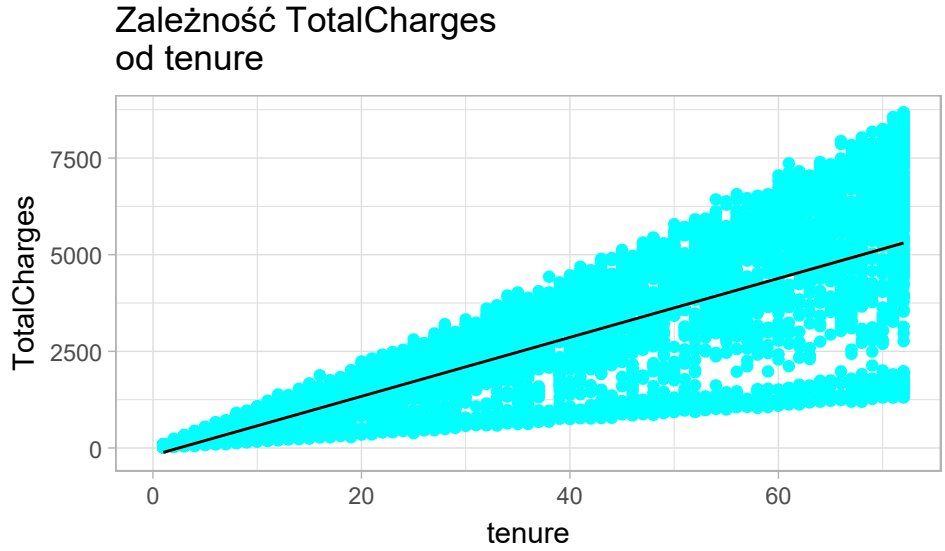

Rysunek 3: Wykres rozrzutu zmiennej Totatl Charges i tenure

Z Rysunku 3 wynika, że liczba miesięcy, przez którą klient pozostawał w firmie (zmienna tenure) wpływa na łączną kwotę ogółem wydaną przez niego w czasie (zmienna TotalCharges). Im dłużej nabywca korzystał z usług firmy telekomunikacyjnej, tym łącznie musiał więcej zapłacić.

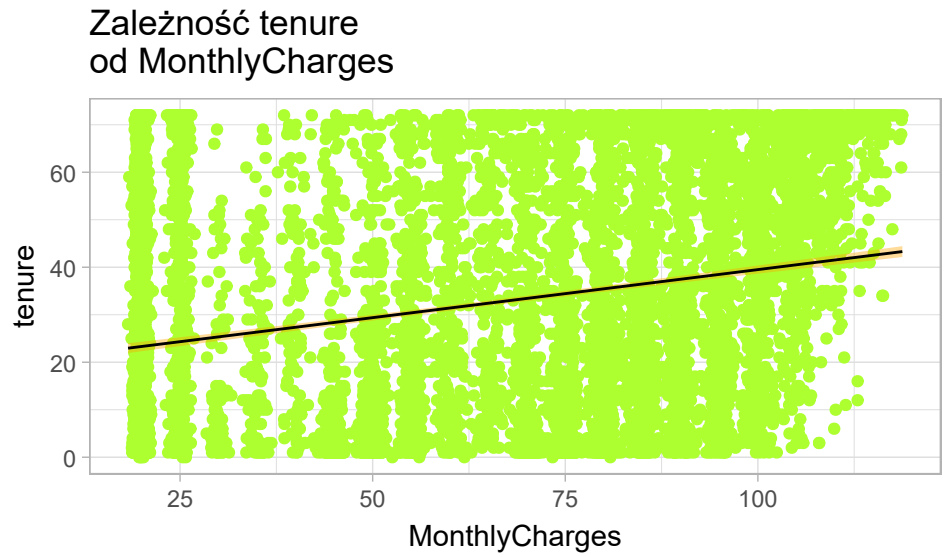

Rysunek 4: Wykres rozrzutu zmiennej tenure i MonthlyCharges

Według wykresu (Rysunek 4) nie istnieje zależność między ilością miesięcy korzystania przez klienta z usług firmy telekomunikacyjnej (zmienna tenure) a miesięcznymi kosztami tych usług (zmienna MonthlyCharges)

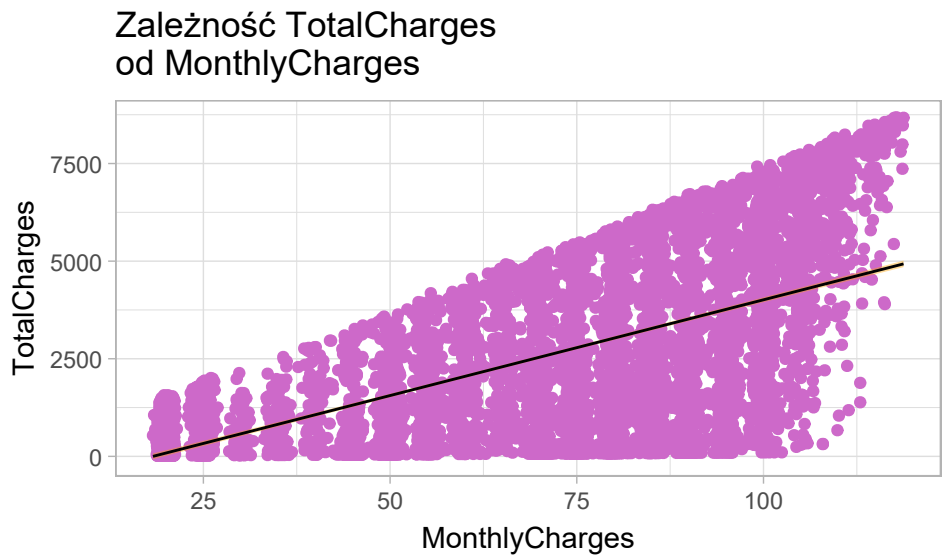

Rysunek 5: Wykres rozrzutu zmiennej Totatl Charges i MonthlyCharges

Zależność między zmiennymi TotalCharges i Monthlycharges (Rysunek 5) ukazuje, że wysokość miesięcznej opłaty (zmienna MonthlyCharges) wpływa na łączną kwotę zapłaconą przez klienta ogółem w czasie korzystania z usług telekomunikacyjnych (zmienna TotalCharges). Im większa była miesięczna płatność, tym łącznie klient wydał więcej pieniędzy na usługi telekomunikacyjne.

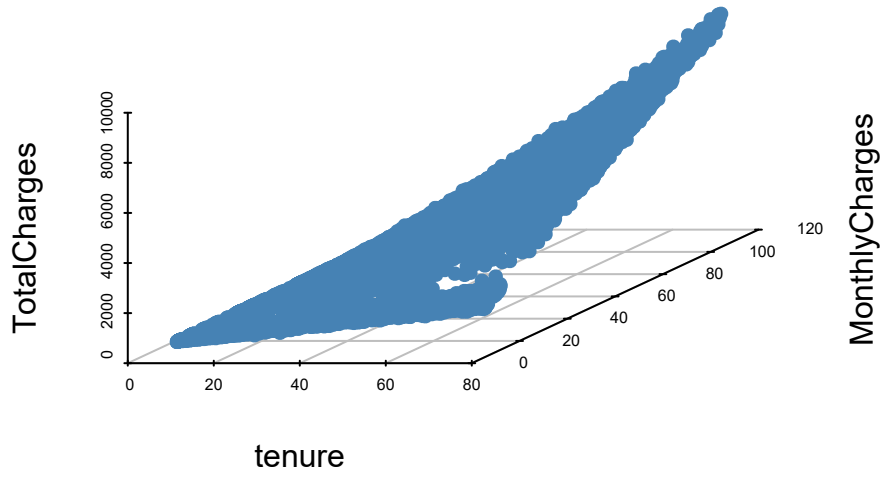

Rysunek 6: Wykres zależności wszystkich zmiennych ciągłych

Z rysunku 6 można zaobserwować zależność pomiędzy trzema zmiennymi ciągłymi. Zarówno długość korzystania z usług przez klienta (zmienna tenure), jak i wysokość miesięcznej opłaty (zmienna MonthlyCharges) znacząco wpływają na całkowity koszt ponoszony przez klienta (zmienna TotalCharges). Występuje tu intuicyjna zależność rosnąca - wraz ze wzrostem czasu trwania umowy oraz wysokości opłat miesięcznych rośnie również łączna kwota wydatków.

2.2 Zmienne jakościowe

2.2.1 Wyznaczenie podstawowych wskaźników sumarycznych

zmienna	Kategoria	Liczność	Proporcja
OnlineSecurity	No	3498.00	63.4 %
	Yes	2019.00	36.6 %
TechSupport	No	3473.00	62.95 %
	Yes	2044.00	37.05 %
InternetService	DSL	2421.00	34.37 %
	Fiber optic	3096.00	43.96 %
	No	1526.00	21.67 %
PaymentMethod	Bank transfer (automatic)	1544.00	21.92 %
	Credit card (automatic)	1522.00	21.61 %
	Electronic check	2365.00	33.58 %
	Mailed check	1612.00	22.89 %
PhoneService	No	682.00	9.68 %
	Yes	6361.00	90.32 %
Contract	Month-to-month	3875.00	55.02 %
	One year	1473.00	20.91 %
	Two year	1695.00	24.07 %
PaperlessBilling	No	2872.00	40.78 %
	Yes	4171.00	59.22 %
StreamingMovies	No	2785.00	50.48 %
	Yes	2732.00	49.52 %
StreamingTV	No	2810.00	50.93 %
	Yes	2707.00	49.07 %
MultipleLines	No	3390.00	53.29 %
	Yes	2971.00	46.71 %

Tabela 3: Miary wybranych zmiennych jakosciowych

Z tabeli 3 można odczytać kilka ciekawych wniosków:

- Aż 63.4 % klientów nie posiada zabezpieczenia internetowego (zmienna OnlineSecurity);
- 62.95 % klientów nie korzysta z usług serwisu technicznego (zmienna TechSupport);
- Dostępu do Internetu nie posiada aż 21.67 % użytkowników;
- Najbardziej popularna wśród klientów jest technologia światłowodowa (Fiber optic). Korzysta z niej 43.96 %;
- Klienci najczęściej decydują się na płatność za pomocą Electronic check, a najrzadziej używając Credit card (automatic);
- Jedynie 9.68 % klientów nie korzysta z usług telefonicznych;

- Najczęstszym rodzajem podpisywanej umowy jest Month-to-month, czyli umowa miesięczna;
- 49.07 % osób ogląda przez sieć transmisje z kanałów telewizyjnych, a 49.52 % korzysta z możliwości oglądania filmów/seriali z portali streamingowych;
- Telefon stacjonarny posiada 46.71 % klientów;
- Większość usługobiorców (bo aż 59.22 %) otrzymuje swoje rachunki i faktury elektronicznie.

2.2.2 Wykresy rozkładów

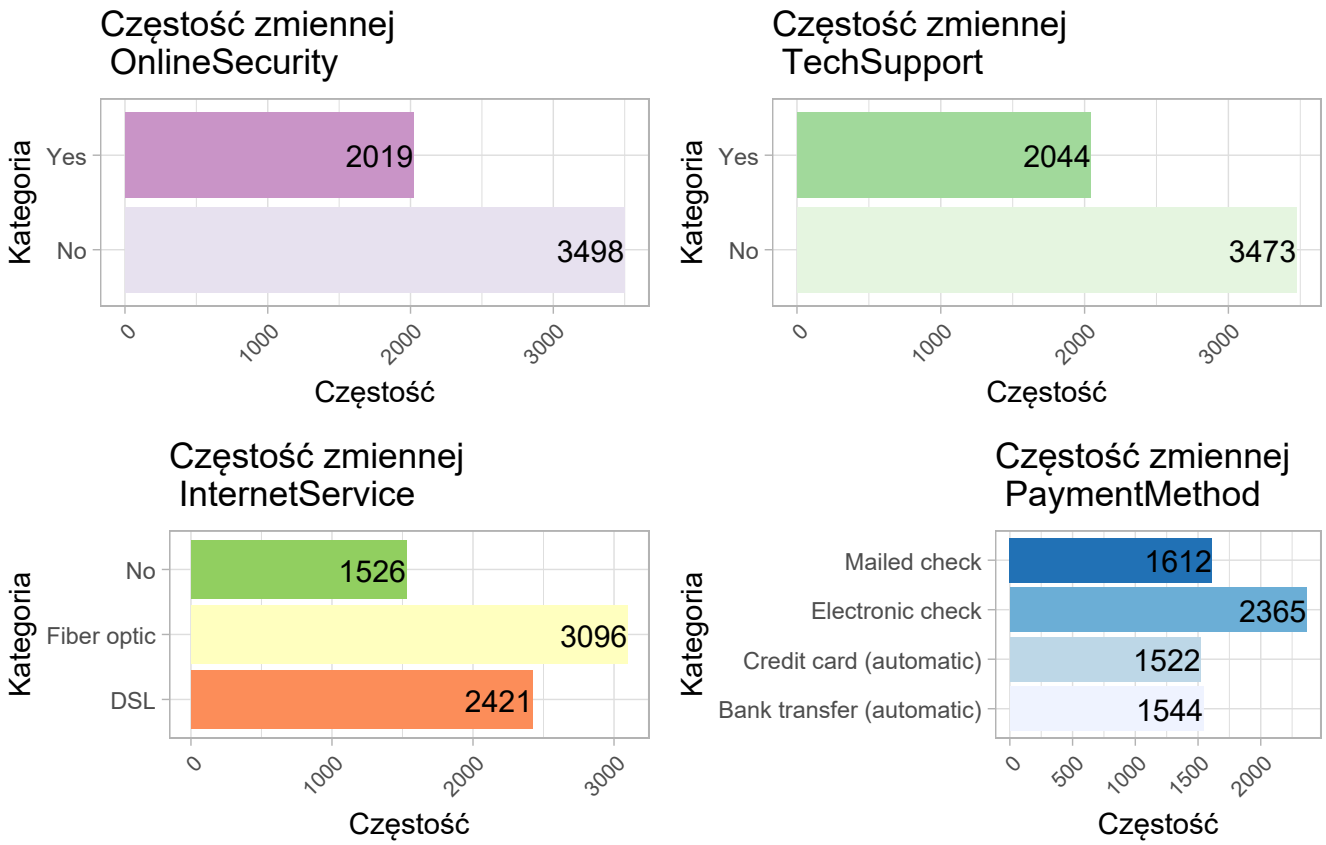

Rysunek 7: Wykresy słupkowe wybranych zmiennych ilościowych

Z Rysunku 7 można odczytać częstość występowania poszczególnych kategorii zmiennych jakościowych. Zaś tylko 2019 klientów korzysta z zabezpieczenia internetowe (zmienna OnlineSecurity), a 3498 usługobiorców nie korzysta z tej opcji.

Ponadto większość nabywców, bo aż 3473 nie korzysta z pomocy technicznej (zmienna TechSupport). Ta liczba znacznie przewyższa klienttów wspomagających się tą możliwością, których jest 2044.

Zaskakujące jest, że aż 1526 ankietowanych nie posiada dostępu do Internetu (zmienna InternetService). Dla pozostałych osób najczęściej wybieranym sposobem dostawy Internetu jest światłowód (Fiber optic) i aż 3096 zainteresowanych zdecydowało się na te usługi. Drugim popularnym dostawcą jest DSL, z którego korzysta 2421.

Klienci decydują się aż na 4 metody płatnicze (zmienna PaymentMethod). W kolejśności od najbardziej do najmniej popularnych :

- Czek elektroniczny(Electronic check) - 2365 klientów;
- Czek wysłany pocztą (Mailed check) - 1612 klientów;
- Automatyczny przelew bankowy (Bank transfer(automatic)) - 1544 klientów;
- Automatyczna płatność kartą kredytową (Credit card (automatic)) -1522 klientów.

Kategorie *Mailed check*, *Credit card(automatic)* i *Bank transfer (automatic)* charakteryzują się podobną popularnością

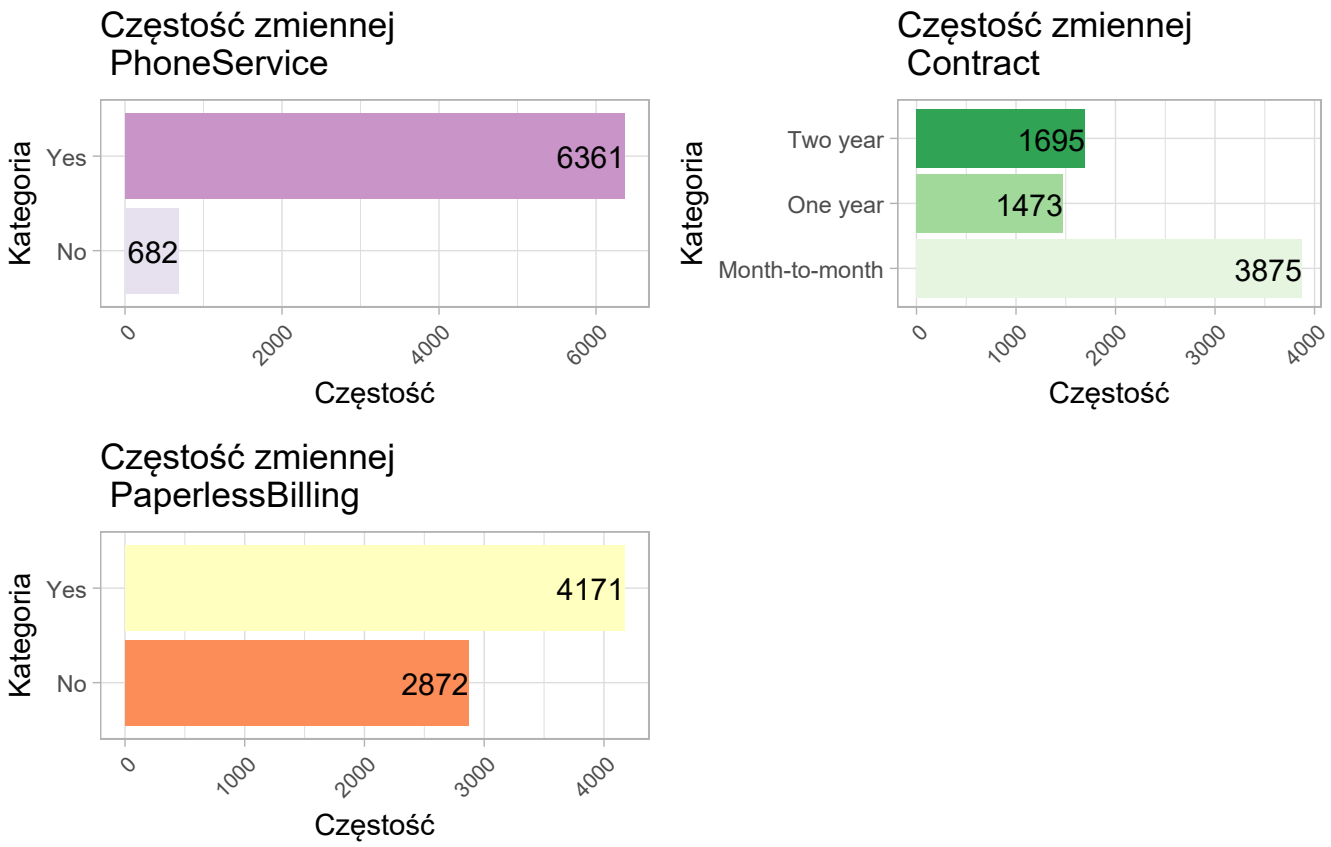

Rysunek 8: Wykresy słupkowe wybranych zmiennych ilościowych z wysoko różniącymi się wartościami

W przeciwieństwie do Rysunku 7, który przedstawiał typowe rozkłady zmiennych, Rysunek 8 prezentuje zmienne, dla których znacząco jest zachowany jakiś trend. Z usług telefonicznych

korzysta aż 6361. Jak widać, jest to znacząco więcej, bo aż o 5679 klientów (tylko 682 osób nie korzysta z serwisu telefonicznego).

Klienci decydują się aż na 3 rodzaje umowy. W kolejności od najbardziej do najmniej popularnych:

- 3875 klientów decyduje się na podpisanie umowy opłacanej co miesiąc (Month-to-month);
- 1695 usługobiorców płaci raz na dwa lata (Two year);
- 1473 kupujących wybrało płatność raz na rok (One year).

Opcja Month-to-month jest zdecydowanie dominującą i zyskała największą popularność.

Dodatkowo widać, że aż 4171 kupujących odeszło z tradycyjnego sposobu opłacania faktur i przeniosła się do elektronicznego systemu opłacania rachunków. Tylko 2872 klientów zostało przy tradycyjnej metodzie otrzymywania opłat, co świadczy o trendzie przechodzenia na opcje elektroniczne.

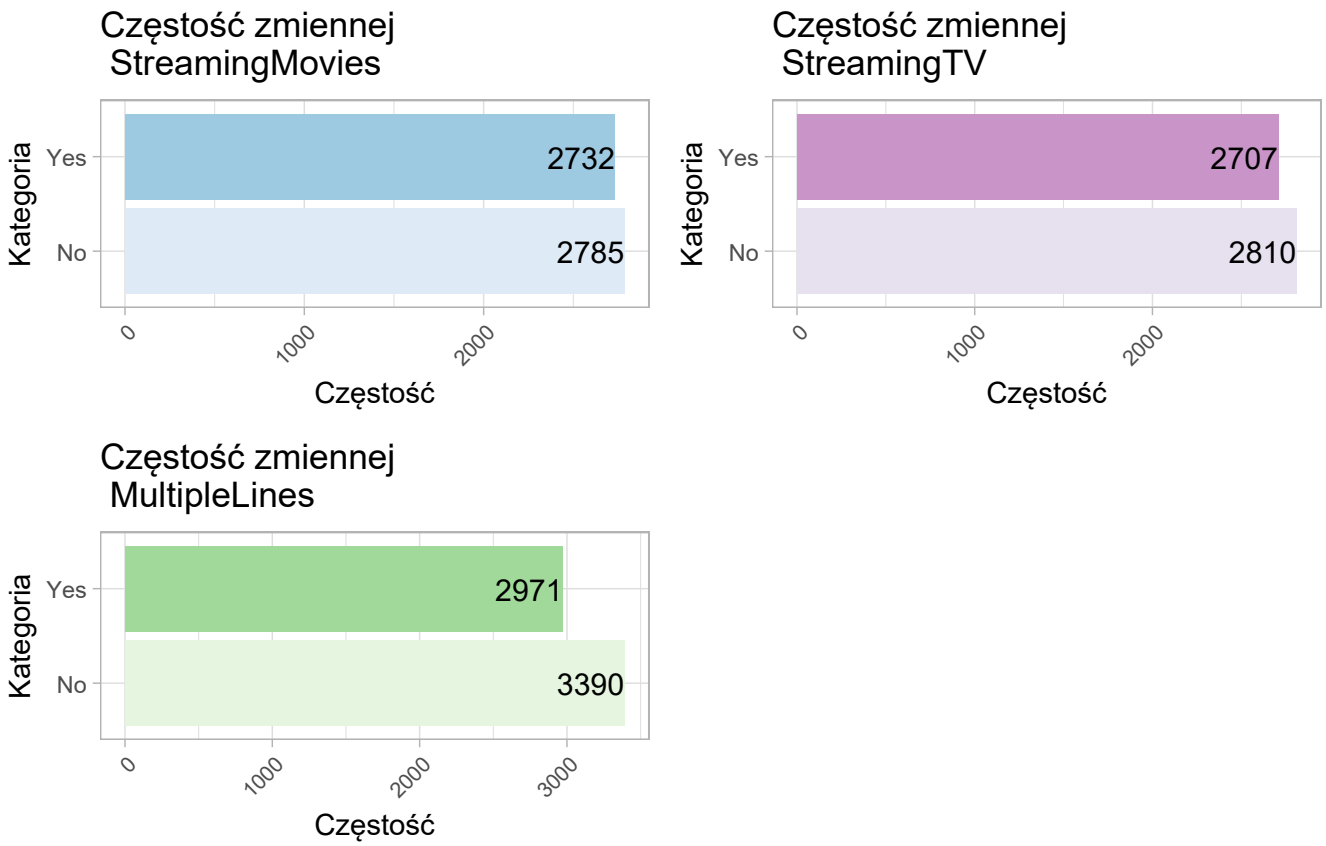

Rysunek 9: Wykresy słupkowe wybranych zmiennych ilościowych z wartościami bliskimi remisu

Z Rysunku 9 można zaobserwować częstość występowania poszczególnych kategorii zmiennych

jakościowych dla których kategorie przyjmują podobne wartości. Dokładnie 2732 użytkowników decyduje się korzystać z platform streamingowych do oglądania filmów/seriali. Niemniej jednak wciąż 2785 klientów nie używa tej usługi. Łatwo jednak zauważyć, że podział ukazuje, że klienci są mocno podzieleni w tej kwestii. Analogiczna, sytuacja występuje w przypadku telewizji internetowej (z usług korzysta 2707 klientów, a 2810 osób unika tej opcji) oraz posiadania telefonów stacjonarnych (opcję tą ma 2971 kupujących, a 3390 z nich nie dysponuje telefonem stacjonarnym).

3 Etap 3 - Analiza opisowa z podziałem na grupy

3.1 Analiza zmiennych ilościowych z podziałem na lojalnych i odchodzących klientów

zmienna	minimum	mediana	srednia	maximum	dominanta	średnia ucinana
tenure	1.000	10.000	17.979	72.000	1.000	14.735
MonthlyCharges	18.850	79.650	74.441	118.350	74.400	76.796
TotalCharges	18.850	703.550	1531.796	8684.800	20.200	1158.880

Tabela 4: Miary położenia dla klientów, którzy zrezygnowali

zmienna	minimum	mediana	srednia	maximum	dominanta	średnia ucinana
tenure	0.000	38.000	37.570	72.000	72.000	37.762
MonthlyCharges	18.250	64.425	61.265	118.750	20.050	60.530
TotalCharges	18.800	1683.600	2555.344	8672.450	19.750	2282.795

Tabela 5: Miary położenia dla klientów, którzy nie zrezygnowali

Z zestawienia tabel 4 i 5 można odczytać, że dla klientów, którzy zrezygnowali, zakres zmiennej tenure wynosi od 1 do 72, zmiennej MonthlyCharges od 18.85 do 118.35, natomiast zmiennej TotalCharges od 18.85 do 8684.8.

Dla klientów, którzy nie zrezygnowali, zmienna tenure przyjmuje wartości od 0 do 72, zmienna MonthlyCharges od 18.25 do 118.75, natomiast zmienna TotalCharges od 18.8 do 8672.45.

Wskaźniki wyliczone w tabelach wskazują, że zmienna tenure przyjmuje większe wartości dla klientów, którzy nie zrezygnowali z usług firmy. Podobnie łączne opłaty (TotalCharges) są raczej wyższe dla klientów lojalnych. Natomiast klienci, którzy zrezygnowali, zazwyczaj płacili wyższe miesięczne opłaty.

zmienna	wariancja	odchylenie standradowe	rozstep proby	rozstep miedzy-kwartylowy
tenure	381.465	19.531	71.000	27.000
MonthlyCharges	608.414	24.666	99.500	38.050
TotalCharges	3575211.596	1890.823	8665.950	2196.800

Tabela 6: Miary rozproszenia dla klientów którzy zrezygnowali

zmienna	wariancja	odchylenie standradowe	rozstep proby	rozstep miedzy-kwartylowy
tenure	581.474	24.114	72.000	46.000
MonthlyCharges	966.753	31.093	100.500	63.300
TotalCharges	5426369.838	2329.457	8653.650	3686.300

Tabela 7: Miary rozproszenia dla klientów którzy nie zrezygnowali

Z zestawienia tabel 6 i 7 można wywnioskować, że lojalni klienci mają większe rozproszenie wszystkich miar. Klienci rezygnujący zwykle są bardziej podobni do siebie pod względem długości współpracy (zmienna tenure) i wykazują mniej zróżnicowane wydatki (zmienne MonthlyCharges i TotalCharges).

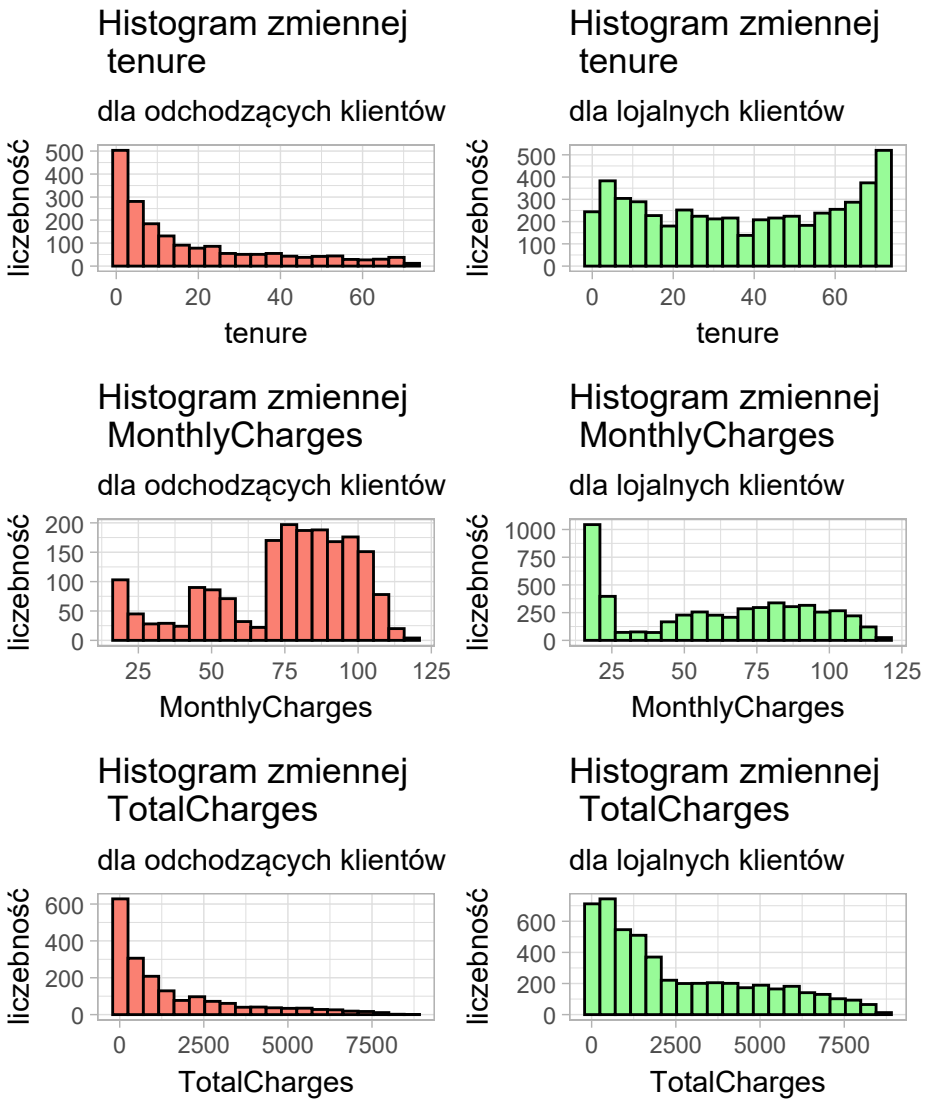

Rysunek 10: Histogramy dla zmiennych ilościowych (tenure, MonthlyCharges, TotalCharges) z podziałem na odchodzących i lojalnych klientów

Z zestawienia histogramów z podziałem na dwie grupy klientów (Rysunek 10) wynikają następujące obserwacje i wnioski:

- Histogram zmiennej tenure dla byłych klientów jest prawostronnie skośny, ze skośnością 1.15 sugerując,że klienci odchodzą raczej po krótkim czasie współpracy z firmą. Histogram zmiennej tenure dla lojalnych klientów jest symetryczny, zbliżony do rozkładu jednostajnego, posiada skośność równą -0.03

- Z histogramów zmiennej MonthlyCharges wynika, że byli klienci płacili miesięcznie więcej niż klienci, którzy nie zrezygnowali. Dla klientów którzy zrezygnowali rozkład jest dwu-modalny, lewostronnie skośny, ze skośnością równą -0.73. Natomiast dla lojalnych klientów wykres jest w przybliżeniu symetryczny ze skośnością -0.03

- Rozkłady zmiennej TotalCharges charakteryzują się podobieństwem w obu grupach i pozostają prawostronnie skośne ze skośnościami 1.51 i 0.81

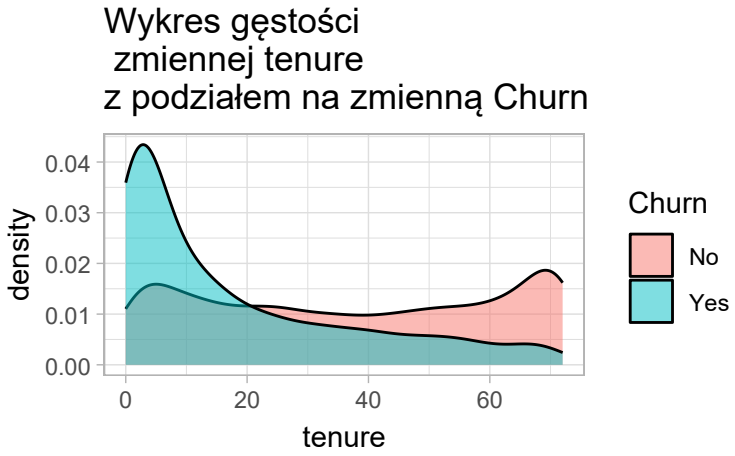

Rysunek 11: Porównanie rozkładu zmiennej tenure dla dwóch grup: lojalnych i odchodzących klientów (gęstości empiryczne)

Wykres gęstości zmiennej tenure (Rysunek 11) potwierdza istotne różnice w długości współpracy między klientami lojalnymi i byłymi. Okres współpracy klientów lojalnych jest bardziej zróżnicowany i ma charakter zbliżony do rozkładu jednostajnego, natomiast klienci którzy rezygnują, wykazują tendencję do odchodzenia głównie na początku współpracy z firmą.

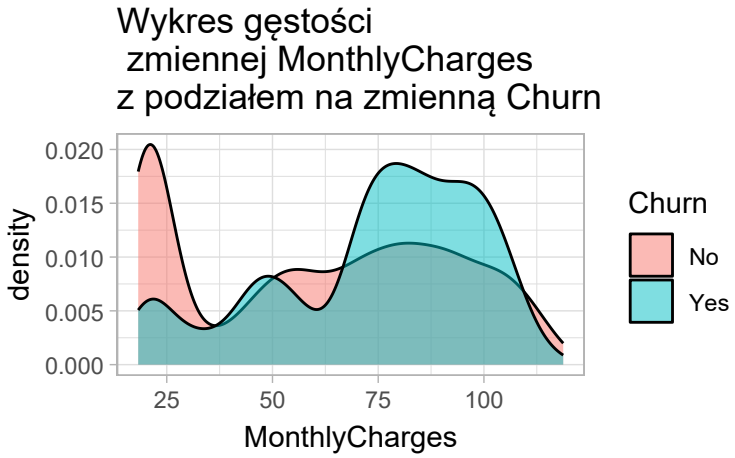

Rysunek 12: Porównanie rozkładu zmiennej MonthlyCharges dla dwóch grup: lojalnych i odchodzących klientów (gęstości empiryczne)

Rozkład zmiennej MonthlyCharges (Rysunek 12) wskazuje, że lojalni klienci najczęściej płacą miesięcznie niższe stawki, natomiast klienci, którzy rezygnują, ponoszą zazwyczaj wyższe opłaty.

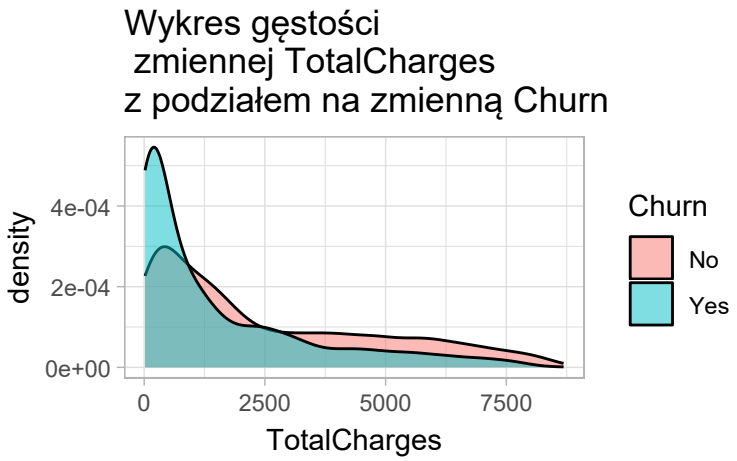

Rysunek 13: Porównanie rozkładu zmiennej TotalCharges dla dwóch grup: lojalnych i odchodzących klientów (gęstości empiryczne)

Rozkłady zmiennej TotalCharges (Rysunek 13) są podobne w obu grupach klientów. Jednak prawdopodobieństwo ponoszenia najniższych opłat jest wyższe dla klientów lojalnych.

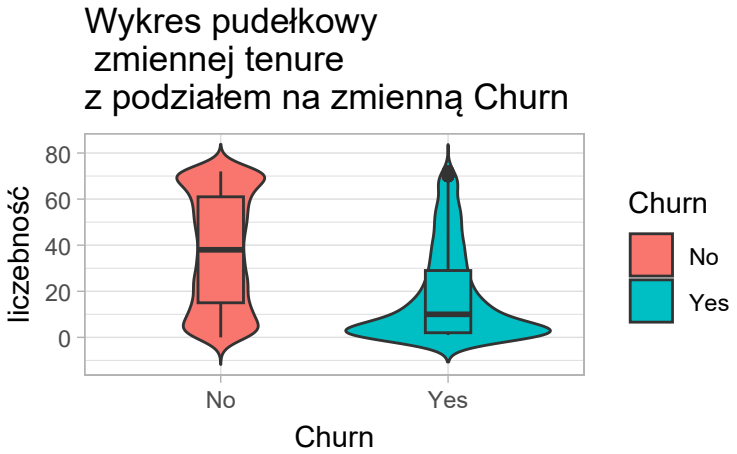

Rysunek 14: Porównanie rozkładu zmiennej tenure dla dwóch grup: lojalnych i odchodzących klientów (wykresy skrzypcowe)

Wykresy skrzypcowe i pudełkowe zmiennej tenure (Rysunek 14) wskazują na istotne różnice między grupami klientów. Lojalni klienci charakteryzują się bardziej zróżnicowanym okresem współpracy, natomiast klienci, którzy odeszli, zwykle współpracują z firmą przez krótki czas, co widać po dużym zagęszczeniu wartości przy niskich poziomach tenure oraz zdecydowanie niższej medianie.

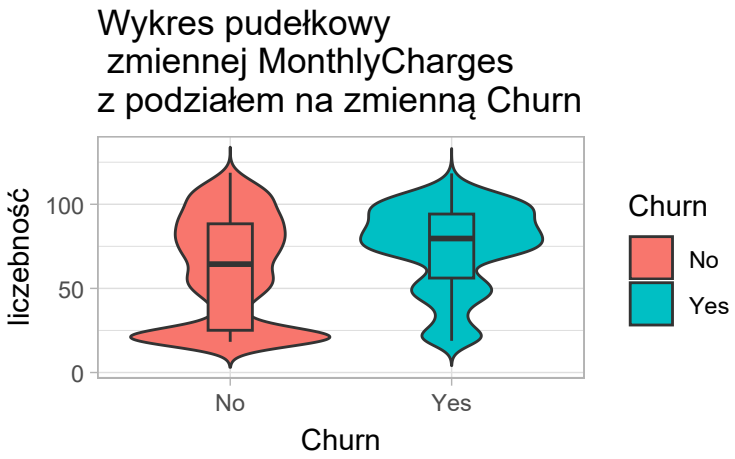

Rysunek 15: Porównanie rozkładu zmiennej MonthlyCharges dla dwóch grup: lojalnych i odchodzących klientów (wykresy skrzypcowe)

Z wykresów skrzypcowych i pudełkowych dla zmiennej MonthlyCharges (Rysunek 15) można wywnioskować, że wśród klientów lojalnych istnieje dużo większa grupa płacąca niższe miesięczne stawki, co widać po dużym zagęszczeniu wartości przy niskich poziomach. W przypadku klientów, którzy odeszli, wykres pokazuje odwrotną tendencję, czyli największe zagęszczenie występuje przy wyższych poziomach opłat.

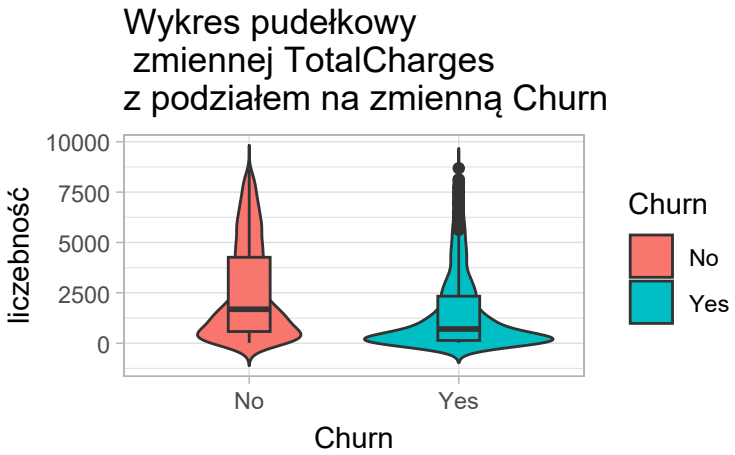

Rysunek 16: Porównanie rozkładu zmiennej TotalCharges dla dwóch grup: lojalnych i odchodzących klientów (wykresy skrzypcowe)

Wykresy skrzypcowe i pudełkowe zmiennej TotalCharges (Rysunek 16) są podobne w obu grupach klientów. Jednak opłaty całkowite dla byłych klientów mają niższą medianę oraz większe zagęszczenie wartości przy niskich poziomach w porównaniu do klientów lojalnych. Dodatkowo na podstawie wartości odstających w grupie byłych klientów można wywnioskować, że klienci rezygnujący rzadko generują dla firmy duży zysk.

Rysunek 17: Analiza zależności dla par zmiennych ciągłych (tenure, MonthlyCharges, TotalCharges), z podziałem na odchodzących i lojalnych klientów (wykresy rozrzutu)

Na wykresach zależności (Rysunek 17), podobnie jak w przypadku analizy bez podziału na grupy, pojawiają się dość logiczne, liniowe zależności między TotalCharges i MonthlyCharges oraz między TotalCharges i tenure. Różnicę między grupami klientów pokazuje wykres rozrzutu zmiennej MonthlyCharges względem tenure. W przypadku klientów lojalnych zależność między tymi zmiennymi nie jest widoczna, punkty są równomiernie rozłożone. Natomiast w grupie klientów, którzy rezygnują, rzadko pojawiają się rekordy łączące długi okres współpracy z niskimi opłatami miesięcznymi.

3.2 Analiza zmiennych jakościowych z podziałem na lojalnych i odchodzących klientów

Zmienne uwzględnione w analizie to te, w których proporcje różnią się najbardziej między grupami klientów.

zmienna	Kategoria	Liczność	Proporcja
OnlineSecurity	No	1461.00	83.2 %
	Yes	295.00	16.8 %
TechSupport	No	1446.00	82.35 %
	Yes	310.00	17.65 %
InternetService	DSL	459.00	24.56 %
	Fiber optic	1297.00	69.4 %
	No	113.00	6.05 %
PaymentMethod	Bank transfer (automatic)	258.00	13.8 %
	Credit card (automatic)	232.00	12.41 %
	Electronic check	1071.00	57.3 %
	Mailed check	308.00	16.48 %
PaperlessBilling	No	469.00	25.09 %
	Yes	1400.00	74.91 %
Contract	Month-to-month	1655.00	88.55 %
	One year	166.00	8.88 %
	Two year	48.00	2.57 %

Tabela 8: Miary wybranych zmiennych jakosciowych dla odchodzących klientów

zmienna	Kategoria	Liczność	Proporcja
OnlineSecurity	No	2037.00	54.16 %
	Yes	1724.00	45.84 %
TechSupport	No	2027.00	53.9 %
	Yes	1734.00	46.1 %
InternetService	DSL	1962.00	37.92 %
	Fiber optic	1799.00	34.77 %
	No	1413.00	27.31 %
PaymentMethod	Bank transfer (automatic)	1286.00	24.86 %
	Credit card (automatic)	1290.00	24.93 %
	Electronic check	1294.00	25.01 %
	Mailed check	1304.00	25.2 %
PaperlessBilling	No	2403.00	46.44 %
	Yes	2771.00	53.56 %
Contract	Month-to-month	2220.00	42.91 %
	One year	1307.00	25.26 %
	Two year	1647.00	31.83 %

Tabela 9: Miary wybranych zmiennych jakosciowych dla lojalnych klientów

Z zestawienia tabel 8 i 9 można odczytać,że:

- Aż 83.2 % klientów odchodzących nie posiada zabezpieczenia internetowego (zmienna OnlineSecurity), w przypadku klientów lojalny z tej usługi niekorzysta 54.16 %.
- 82.35 % klientów odchodzących oraz 53.9 % klientów lojalnych nie korzysta z usług serwisu technicznego (zmienna TechSupport).
- Dostępu do Internetu nie posiada jedynie 6.05 % odchodzących klientów, a w przypadku klientów lojalnych jest to aż 27.31 %.
- Byli klienci w zdecydowanej wiekszości korzystają ze światłowodu (69.4 %).
- Byli klienci najczęściej decydowali się płacić za pomocą Electronic check, a u klientów lojalnych wszystkie możliwe metody płatności zostały wybierane z podobną czestością.
- Zdecydowa większość, czyli aż 74.91 % klientów odchodzących jest zainteresowanych fakturą elektroniczną.
- Jeszcze większe procenty możemy zaobserwować analizując zmienną Contract, gdzie 88.55 % klientów odchodzących wybiera bardziej elastyczne kontrakty miesięczne, podczas gdy lojalni klienci równie chętnie sięgają po dłuższe kontrakty.

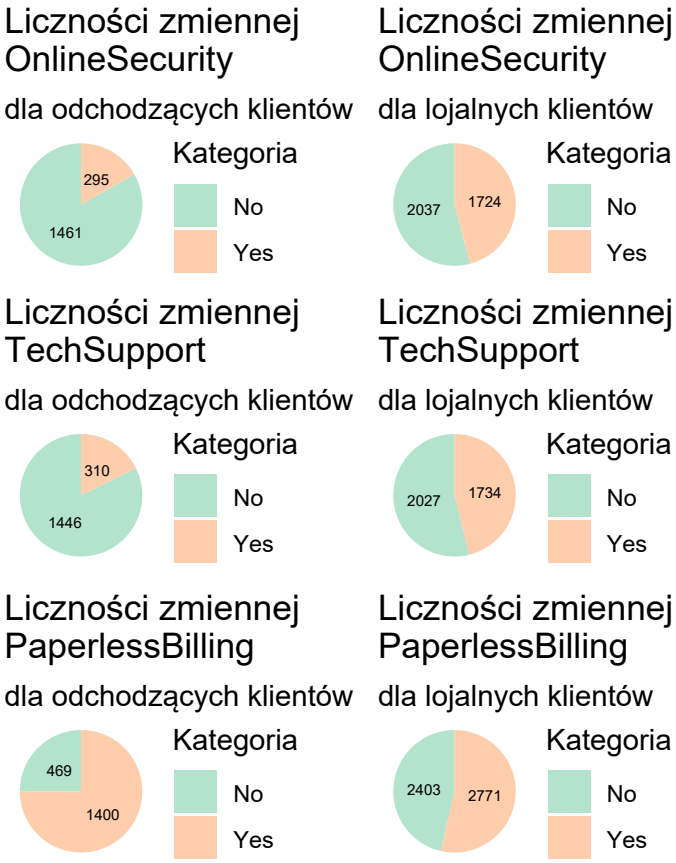

Rysunek 18: Diagramy kołowe dla wybranych zmiennych jakościowych binarnych z podziałem na odchodzących i lojalnych klientów

Z zestawienia wykresów kołowych zmiennych jakościowych (Rysunek 18) można wywnioskować, że:

Klienci, którzy odeszli z firmy, znacznie rzadziej korzystali z usług Online Security i Tech Support oraz częściej decydowali się na wybór rozliczeń bezpapierowych (zmienna Paperless-Billing). W przypadku klientów lojalnych cechy te posiada około połowa grupy.

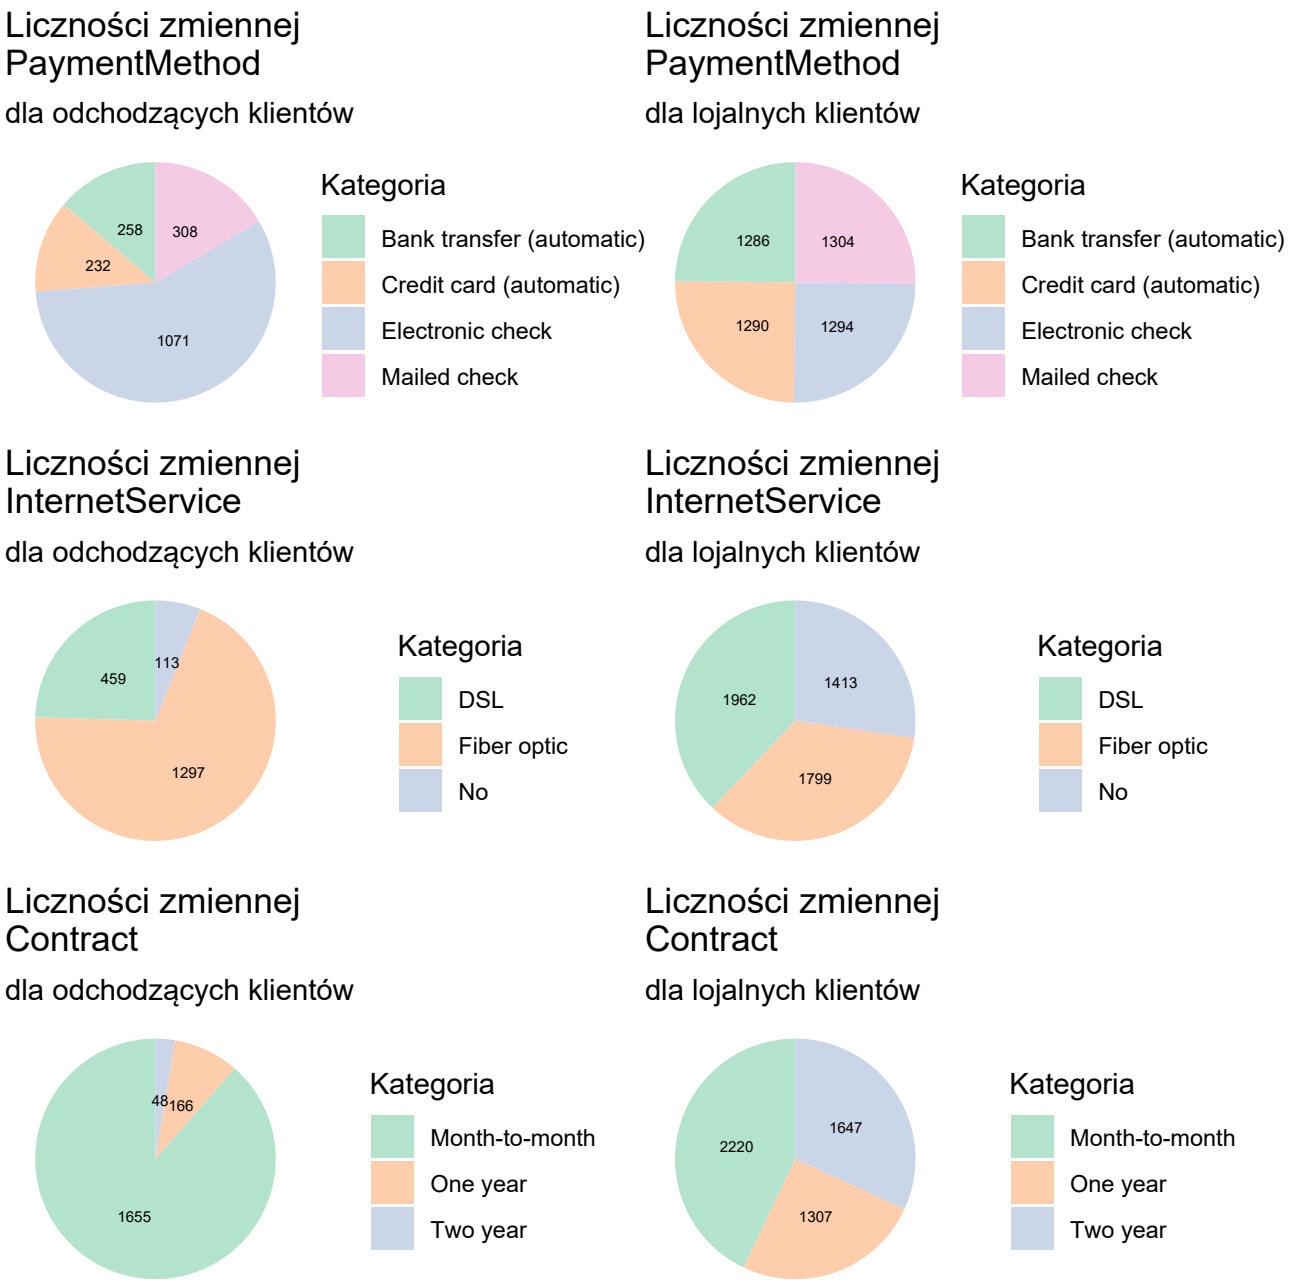

Rysunek 19: Diagramy kołowe dla wybranych zmiennych jakościowych nominalnych z podziałem na odchodzących i lojalnych klientów

Z zestawienia wykresów kołowych zmiennych jakościowych nominalnych (Rysunek 19) można

wywnioskować, że:

- Jeśli chodzi o internet, byli klienci najczęściej korzystali ze światłowodu, podczas gdy w grupie lojalnych klientów wszystkie dostępne możliwości wystepują z podobną częstością.
- Podobną dysproporcję można zauważyć przy metodzie płatności. Wśród lojalnych klientów wszystkie metody są rozłożone w podobny sposób, natomiast wśród byłych klientów dominuje płatność typu electronic check.
- Klienci, którzy rezygnują duża rzadziej decydują sie podpsywać roczne i dwuletnie kontrakty. Podczas gdy wśród lojalnych klientów 3 rodzaje kontraktów są równomiernie rozłożone, u byłych klientów zdecydowanie dominują kontrakty miesięczne.

4 Etap 4 - Podsumowanie i wnioski z przeprowadzonej analizy

4.1 Podsumowanie

a) Podsumowanie i wnioski z poszególnych etapów analizy

- Etap 1 - Przygotowanie danych. Podstawowe informacje o danych

Zbiór danych wykorzystany do analizy to "WA_Fn-UseC_-Telco-Customer-Churn.csv". Jest on dostępny na serwisie kaggle. Dane zawierają 7043 obserwacje oraz 3 zmienne o charakterze ilościowym i 17 zmiennych jakościowych. W danych występuje 11 brakujących wartości w zmiennej TotalCharges, zakodowanych jako NA. W celu przygotowania danych do dalszej analizy zmienna customerID została usunięta i a typ danych dla zmiennej SeniorCitizen został zmieniony.

- Etap 2 - Analiza opisowa - wskaźniki sumaryczne i wykresy

Rozkłady zmiennych ilościowych są zróżnicowane i niesymetryczne. Największą skosność równą 0.96 ma zmienna TotalCharges. Z analizy zależności wynika, że zarówno długość korzystania z usług (tenure), jak i wysokość miesięcznych opłat (MonthlyCharges) wpływają na łączny koszt ponoszony przez klienta (TotalCharges).Zależności te są dość logiczne(tj. im więcej klient płaci firmie miesięcznie tym wyższe będą jego opłaty całkowite, tak samo dłuższe korzystanie z usług zwiększa całkowitą sumę opłat) Nie zaobserwowano natomiast wyraźnej zależności między długością korzystania z usług a miesięcznymi opłatami. W przypadku zmiennych jakościowych większość klientów nie korzysta z usług dodatkowych, takich jak OnlineSecurity czy TechSupport.Zaskakującym wnioskiem z analizy jest fakt, iż aż 21.67 % ankietowanych nie posiada dostępu do Internetu (zmienna InternetService).Klienci decydują się na 4 metody płatnicze (zmienna PaymentMethod). Są to kolejno od najbardziej do najmniej popularnych: czek elektroniczny, czek wysłany pocztą, przelew bankowy oraz płatność kartą kredytową. Zdecydowana większość klientów korzysta z usług telefonicznych (PhoneService) oraz preferuje elastyczne umowy typu month-to-month. Spora grupa osób decyduje się również na elektroniczne faktury. Jednocześnie w przypadku usług takich jak MultipleLines,

StreamingMovies czy StreamingTV klienci są wyraźnie podzieleni(liczba użytkowników i nieużytkowników jest bardzo zbliżona).

- Etap 3 - Analiza opisowa z podziałem na grupy

Klienci lojalni charakteryzują się bardziej zróżnicowanym okresem współpracy (tenure), płacą raczej niższe miesięczne opłaty (MonthlyCharges) oraz częściej korzystają z dodatkowych usług, takich jak OnlineSecurity i TechSupport, w porównaniu do klientów, którzy rezygnują. Klienci odchodzący zazwyczaj współpracują z firmą krótko, ponoszą wyższe miesięczne opłaty i rzadziej korzystają z dodatkowych usług. Częściej korzystają ze światłowodu, decydują się na płatności typu electronic check i wybierają rozliczenia bezpapierowe(PaperlessBilling)

b) Profil klientów firmy:

Klienci korzystający z oferty firmy wykazują się zróżnicowaniem jeśli chodzi o okres współpracy i ponoszone koszty. Jednak można zaobserwować istotne różnice pomiędzy grupami klientów lojalnych i tych którzy odeszli. Klienci lojalni częściej korzystają z dodatkowych usług takich jak OnlineSecurity czy TechSupport. Najczęściej wybieraną usługą internetową (zmienna InternetService) wśród wszystkich klientów oraz klientów odchodzących jest światłowód, podczas gdy lojalni klienci korzystają też z DSL. Natomiast najczęstrza metoda płatności (zmienna PaymentMethod) to electronic check. Chociaż, podobnie jak z internetem, na ten wynik zdecydowanie bardziej wpływają byli klienci, podczas gdy klienci lojalni wybierają metody płatności, bez wyraźnej dominacji jednej formy. Klienci preferują korzystać z rozliczeń bezpapierowych. Usługi,z których klienci korzystają najczęściej to przede wszystkim PhoneService, inne dość popularne usługi (korzysta z nich około połowa klientów) to MultipleLines, StreamingMovies, StreaminTV

c) Przyczyny i przeciwdziałanie odchodzeniu klientów:

- Główną przyczyną odchodzenia klientów wydaje się być wysoki koszt w połączeniu z krótkim okresem korzystania z usług. Takie zestawienie sugeruje, że klienci ponoszą większe koszty już na początku współpracy, co może ich zniechęcać i prowadzić do szybszej rezygnacji.
  Kolejną przyczyna może być ograniczone korzystanie z usług dodatkowych (np OnlineSecurity, TechSupport), można przypuszczać, że odchodzący klienci nie dostrzegają pełnego potencjału usług firmy.
  Ponadto klienci odchodzący częściej korzystają ze światłowodu i wybierają electronic check jako formę płatności a rzadziej decydują się na roliczenia bezpapierowe. Światłowód jest zazwyczaj droższy niż DSL, co jest spójne z wcześniejszą obserwacją o wyższych miesięcznych opłatach wśród klientów odchodzących. Wyższe koszta światłowodu mogą mieć niekorzystny wpływ na klientów i przyczyniać się do ich odchodzenia. Z kolei rezygnacje klientów decydujących się na płatności typu electronic check może wskazywać na mniejszą wygodę tej metody płatności lub mniej zautomatyzowany proces co zniechęca klientów do kontynuowania współpracy. Podobnie nalezy dopuścic możliwośc istnienia problemów z procesem wystawiania e-faktur, które stanowią częsty wybór wśród klientów rezygnujących.

- W celu przeciwdziałaniu odchodzeniu klientów firma powinna podjąć następujące kroki:

1. Oferować promocje i specjalne pakiety dla nowych klientów, szczególnie tych którzy korzystają ze światłowodu, aby skłonić ich do długotrwałej współpracy.

2. Zachęcać nowych klientów do korzystania z usług dodatkowych, takich jak OnlineSecurity i TechSupport, w celu zwiększenia ich zaangażowania.

3. Przeprowadzić dodatkowe analizy (np ankiety wśród klientów) w celu zbadania potencjalnych problemów związanych z płatnościami typu electronic check oraz elektronicznymi fakturami a następnie w oparciu o wyniki usprawnić proces płatności.